



1 復習

$$p(\mathbf{w}, \mathcal{D}) = p(\mathcal{D})p(\mathbf{w}|\mathcal{D}) = p(\mathbf{w})p(\mathcal{D}|\mathbf{w}) \quad (1)$$

$$p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})} \quad (2)$$

2 1.2.6 ベイズ曲線フィッティング

$$p(\mathbf{w}|\mathbf{x}, \mathbf{t}, \alpha, \beta) = \frac{p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta)p(\mathbf{w}|\alpha)}{p(\mathbf{x}, \mathbf{t}, \alpha, \beta)} \quad (3)$$

$$p(\mathbf{w}|\mathbf{x}, \mathbf{t}, \alpha, \beta) \propto p(\mathbf{t}|\mathbf{x}, \mathbf{w}, \beta)p(\mathbf{w}|\alpha) \quad (1.66) \quad (4)$$

上記は、最大事後確率 (MAP; maximum a posteriori) となるが、最大となる \mathbf{w} の点を推定しているだけ。完

全なベイズというには w のすべての値で積分する必要がある。(すなわち、いろいろな w がそれぞれの事後確率で出力され、それぞれの w にて x から t を予想する)。問題としては、 x から t を予測する問題で、訓練例として \mathbf{x}, \mathbf{t} が与えられるので次のようになる。

$$p(t|x, \mathbf{x}, \mathbf{t}) = \int p(t|x, w)p(w|\mathbf{x}, \mathbf{t})dw \quad (1.68) \quad (5)$$

ここで式 (1.60) から、

$$p(t|x, \mathbf{t}, \beta) = \mathcal{N}(t|y(x, w), \beta^{-1}) \quad (1.60)$$

$$p(t|x, \mathbf{t}) = \mathcal{N}(t|y(x, w)) \quad (1.60')$$

式 (1.66) から、事後分布

$$p(w|\mathbf{x}, \mathbf{t}) = \frac{p(\mathbf{t}|\mathbf{x}, w, \beta)p(w|\alpha)}{\sum p(\mathbf{t}|\mathbf{x}, w, \beta)p(w|\alpha)}$$

となり、これらから、式 (1.68) は解析的に解くことができ、

$$p(t|x, \mathbf{x}, \mathbf{t}) = \mathcal{N}(t|m(x), s^2(x)) \quad (1.69)$$

ここで、平均と分散は、

$$m(x) = \beta\phi(x)^T \mathbf{S} \sum_{n=1}^N \phi(x_n)t_n \quad (1.70)$$

$$s^2(x) = \beta^{-1} + \phi(x)^T \mathbf{S} \phi(x) \quad (1.71)$$

となり行列 \mathbf{S} は、

$$\mathbf{S}^{-1} = \alpha \mathbf{I} + \beta \sum_{n=1}^N \phi(x_n)\phi(x_n)^T$$

で与えられる。ここで \mathbf{I} は単位行列で、 $\phi_i(x) = x^i (i = 0, \dots, M)$

3 1.3 モデル選択

最小二乗法の例にて、最適な次数があった。次数のようなモデルの複雑さを、最小二乗法では正則化係数 λ により制御するし、他の学習手法もそのようなパラメータがある。これらは未知の事例に対する予測が最も良いものを選ぶ。

過学習があるので、訓練データとは別に、確認用集合 (検証用集合; validation set) を用意しておき、これらのパラメータを調整し、最後に、テスト用集合 (test set) にて性能の最終評価を行う。

